推理流水线延迟剖析

推理流水线延迟剖析

本文记录 2026-11-05 的延迟优化过程、每一项的实测结论，以及当前基线。所有数字来自板端日志与 `/api/video/stats`，不是估算。

1. 当前基线

```
端到端 processing_age : 46 ms（stdev 0.5，min 46 / max 47）
采集                  : 1280×720 MJPEG 30 fps，丢帧 0
模型                  : YOLO26n 512×512，INT8 类别 + FP16 框
NPU                   : 1188 MHz，Core0/Core1 各一个 worker
CPU                   : performance 调速器，2016 / 2208 MHz（由前端 /api/cpu_freq 控制）
```

46 ms 的构成：

部分	耗时	说明
相机侧	33 ms	驱动时间戳 → DQBUF 返回，UVC 固有的一帧延迟
我们的流水线	13 ms	decode 1 + resize 2 + run 8 + post 1 + 调度 1

2. 测量方法

`yolo timing ms:` 每 10 秒一行：

字段	含义
`capture_to_decode`	帧时间戳 → 开始解码（含相机侧延迟）
`deliver_to_decode`	DQBUF 返回 → 开始解码（应用自身排队）
`decode`	JPEG 硬解 + NV12→RGB
`resize`	letterbox 缩放到模型输入
`inputs` / `run` / `outputs`	NPU 三段
`post`	候选筛选 + NMS

另有 `yolo handoff ms:` 记录"后处理完成 → 显示提交"，实测恒为 0。

`deliver_to_decode = 0` 是关键证据：帧一到就开始处理，`capture_to_decode` 的 33 ms 全部发生在驱动/相机侧。

3. 有效的优化

改动	收益	说明
CPU 调速器 ondemand → performance	**−14 ms**	最大单项。帧间隔内降频使所有 CPU 环节变慢且抖动，E2E 60±7 → 46±0.5；该值由前端 /api/cpu_freq 持久化，仓库默认给 performance

改动	收益	说明
NPU 800 → 1188 MHz	−13 ms（run 34.8→12）	见内核仓 `0005`
模型 640 → 512 输入	−7 ms（run 12→8）	精度同时提升，见量化报告 17
采集 2560×1440 → 1280×720	−5 ms	此前一直误用 1440p
运行时 2.3.0 → 2.5.0	同模型 −25%	官方 notes 的多输入输出 CPU 负载优化
类别输出 NCHW → NHWC	−2 ms（post 4→1）	逐锚点读 80 个分数由跨 5376 字节变连续
框输出 FP16	精度 +2.45 mAP50-95	延迟无变化，见量化报告 16

4. 验证后否定的方案

方案	结论
4 个推理线程	E2E 62→63、`run` 12→13：NPU 只有 2 核，多开在核内串行
解码器超频 702→1000 MHz	解码无变化（7.18→7.71 ms），且有 30–50 ms 偶发长解码
编码器超频	应用不编码，无影响
NV12→letterbox 融合（标量）	8.17 ms，慢于现有"转换 1.11 + resize 1.11"
NMS 候选池 128→64	post 无变化：耗时在逐锚点类别扫描而非候选池
RGA 硬件缩放	硬件在、时钟在跑，但无驱动；移植厂商 rga3 需数天换约 3 ms

5. 剩余空间

方向	预估	代价
采集再降到 640×480	−2 ms（decode 5→1）	录像 720p→480p
NEON 融合 NV12→letterbox	−2~3 ms	需写 NEON 内核
RGA 移植	−2 ms	驱动移植，数天
相机换 CSI 直连	可能削掉 33 ms 的一部分	硬件改动

应用侧已接近该架构下限（13 ms），继续压缩只能动相机链路或硬件加速器。

6. 复现

```
# 调速器（仓库内 config/cpu_freq.conf，应用启动时恢复）
cat /sys/devices/system/cpu/cpufreq/policy4/scaling_governor   # performance
# 阶段耗时
grep "yolo timing" /opt/autonomous-driving-car/logs/*/*.log | tail
# 端到端
curl -s http://127.0.0.1/api/video/stats | grep -o '"processing_age_ms":[0-9]*'
```